


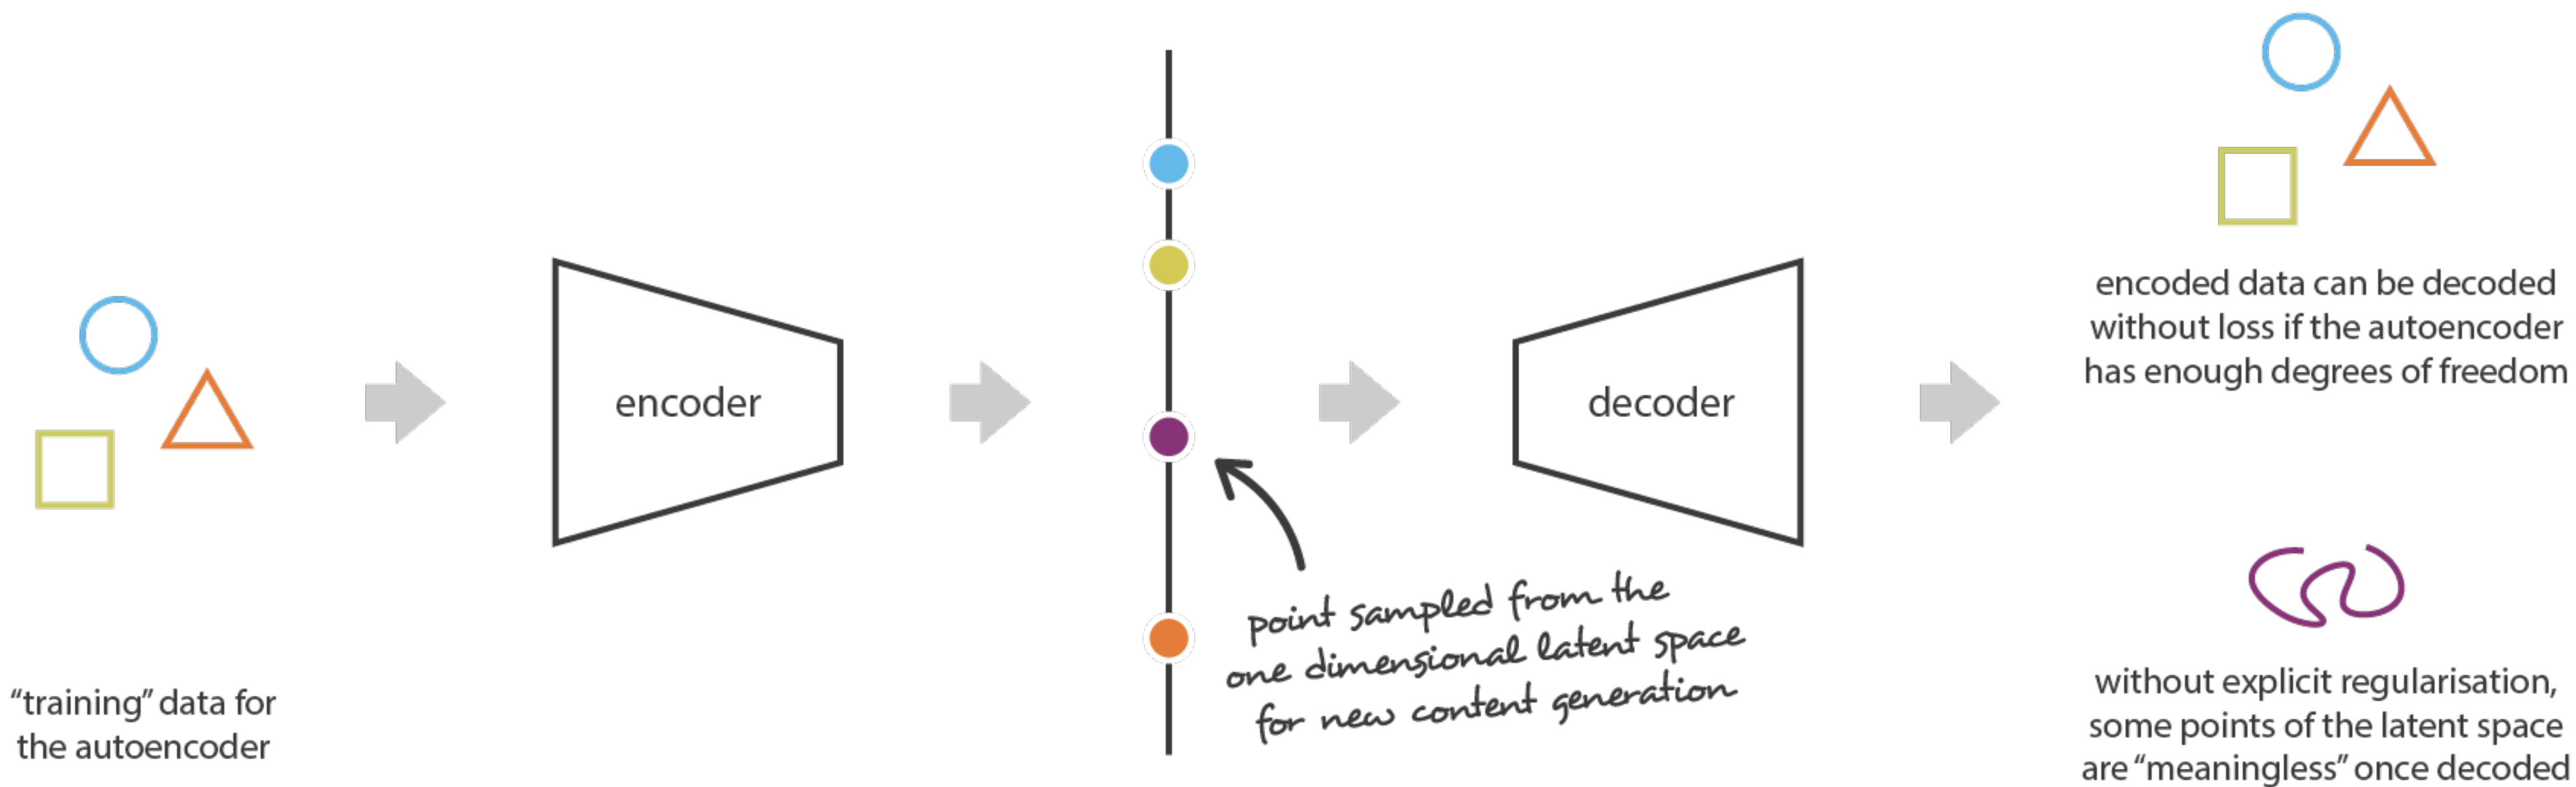
Variational Autoencoders



Что не так с АЕ?

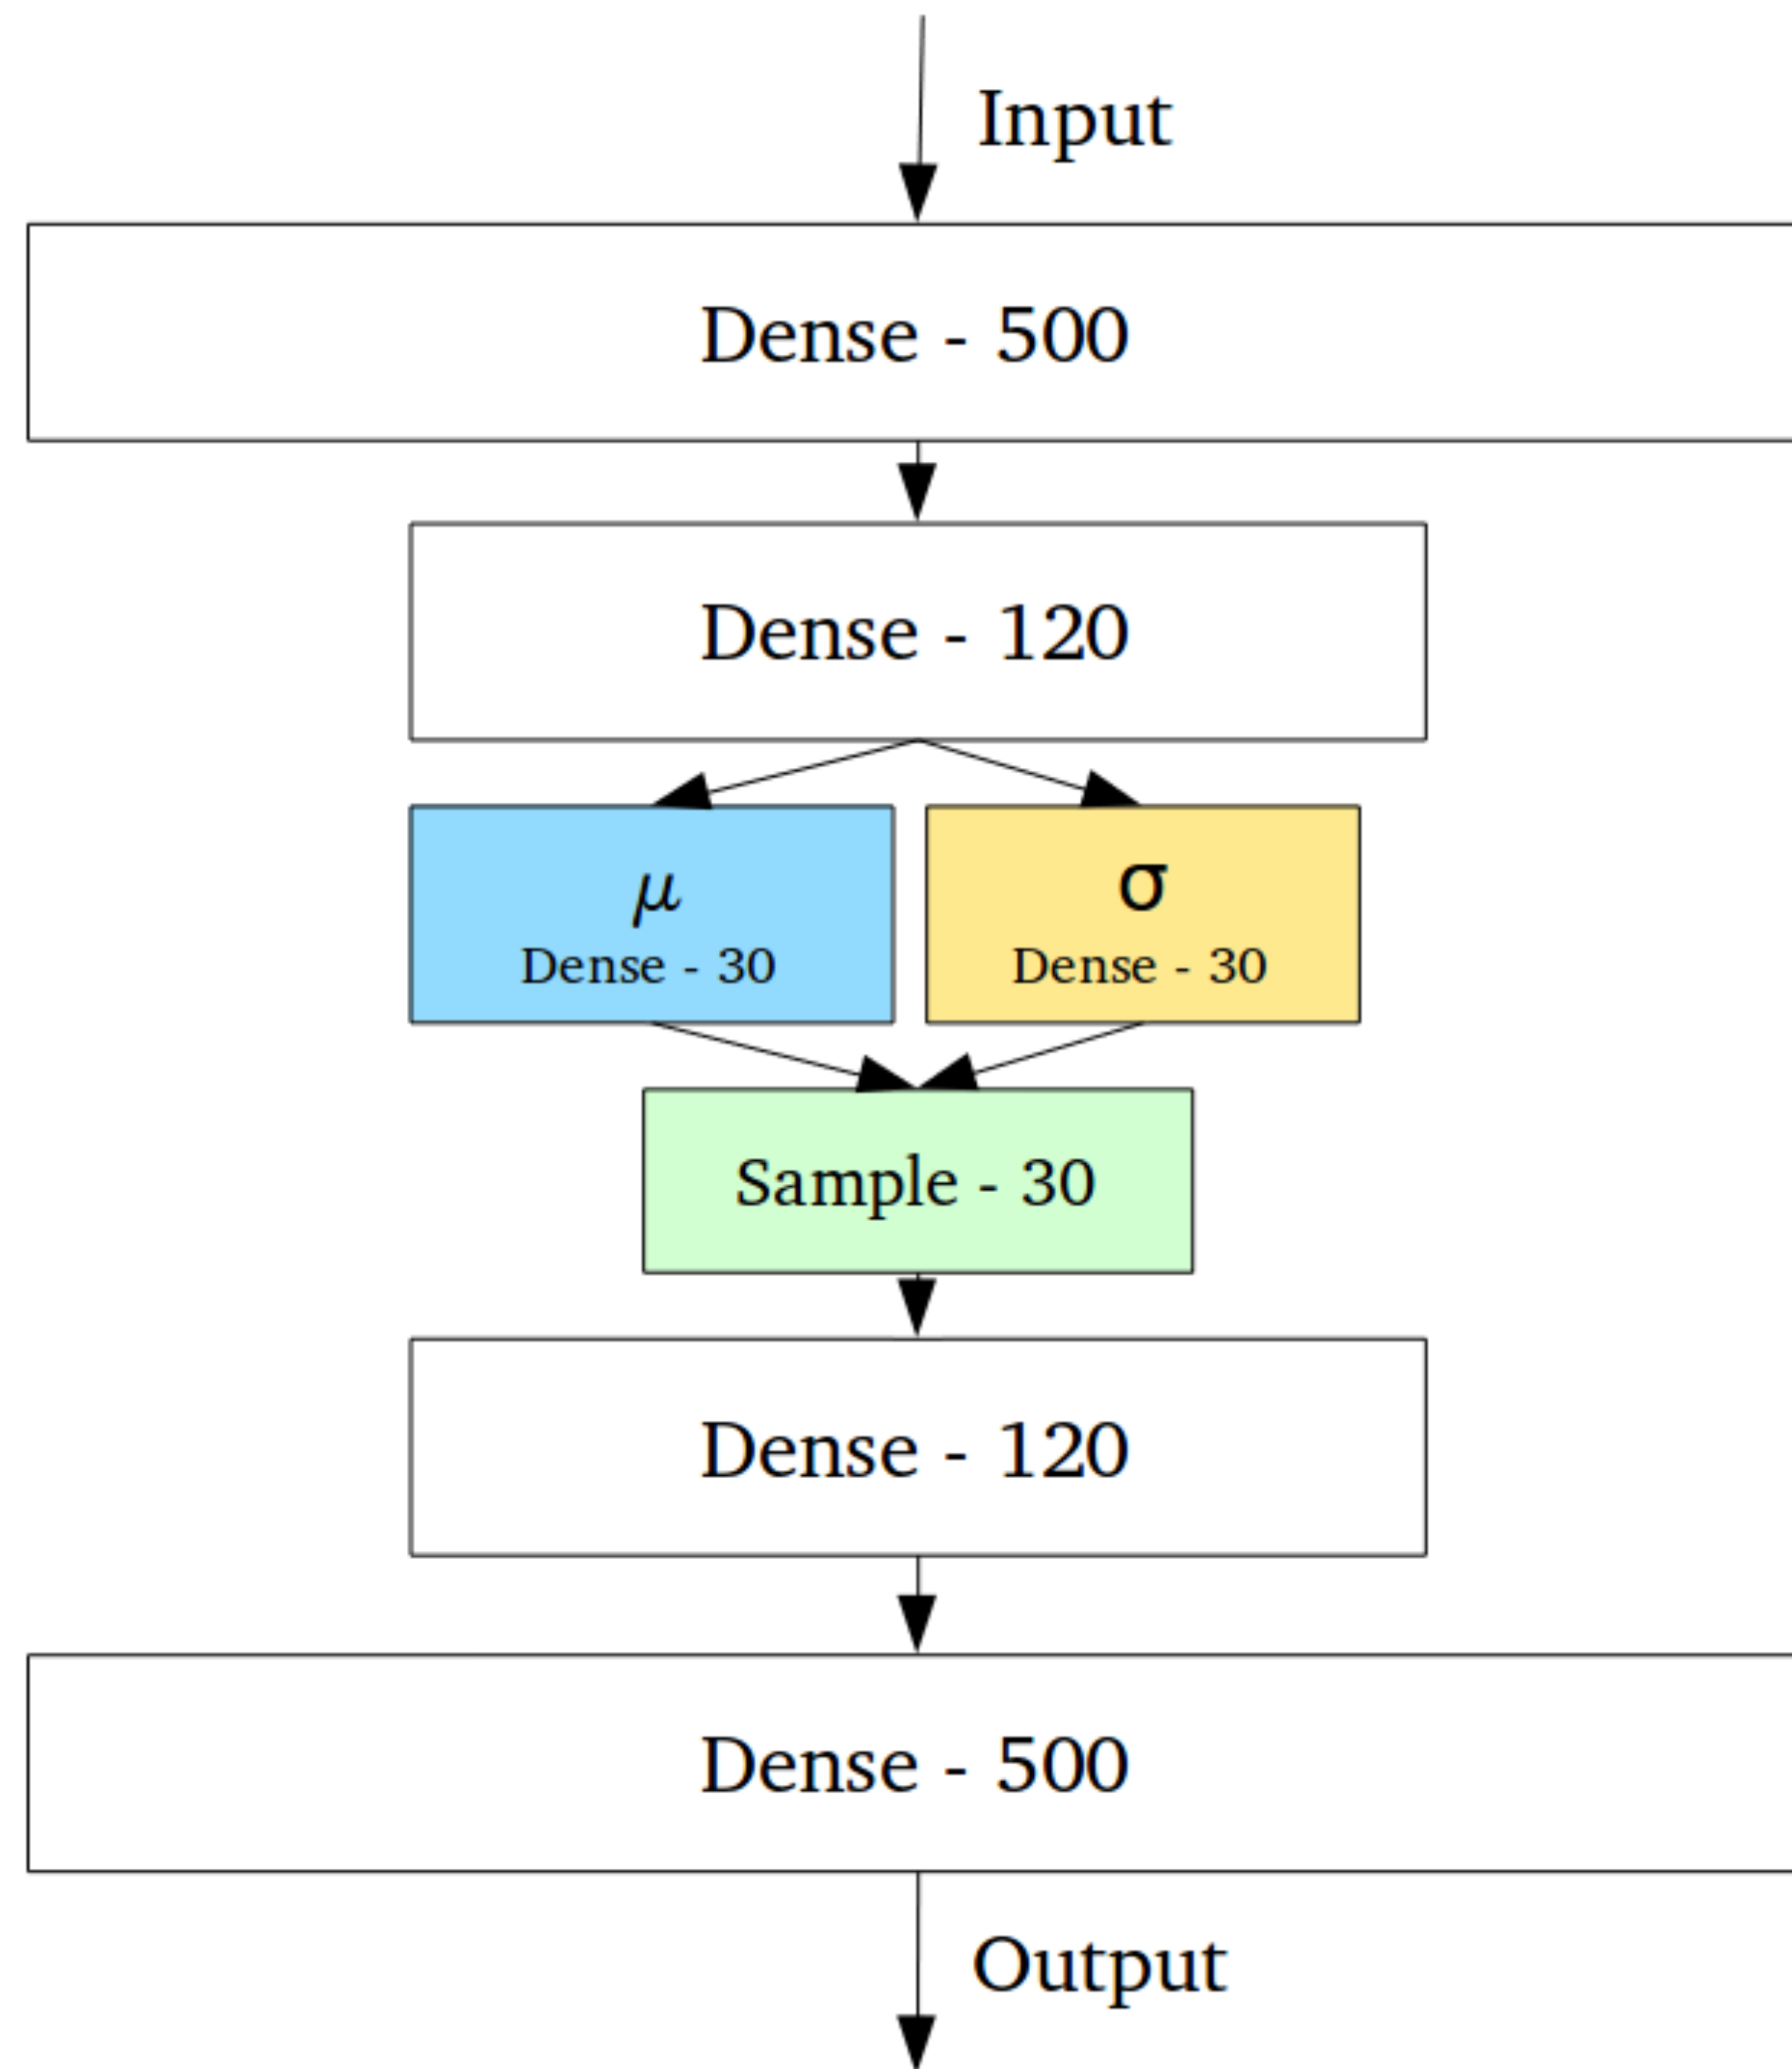
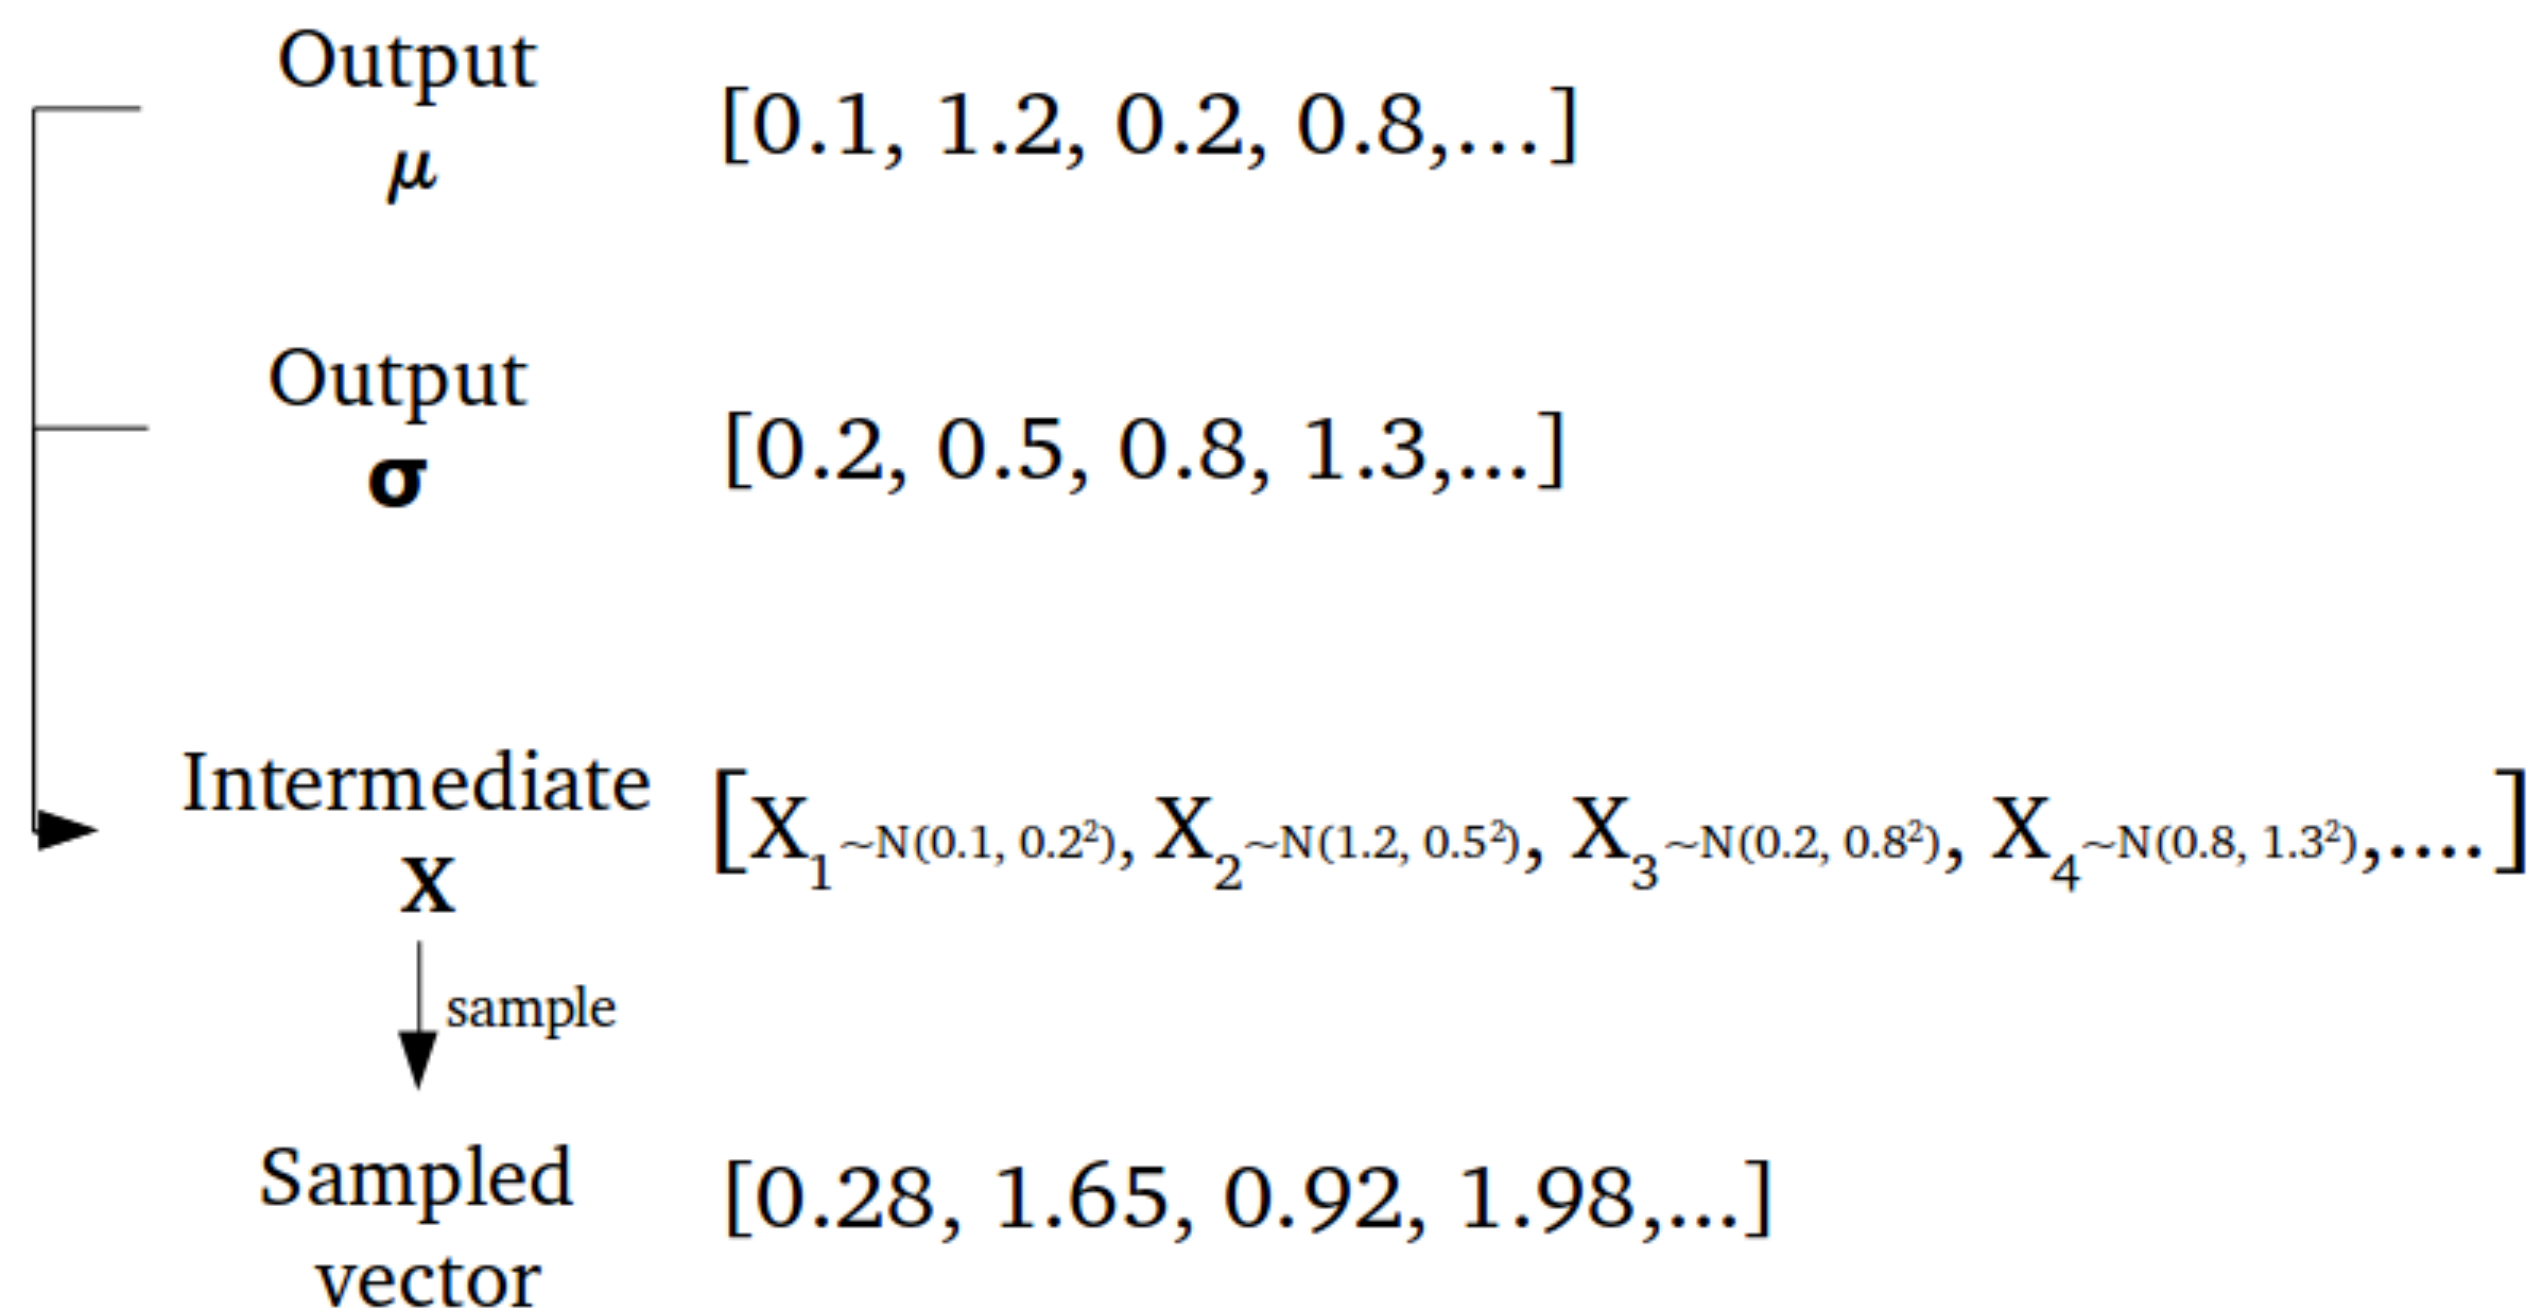
- С точки зрения задачи генерации ~Всё







VAE (в чём смысл?)

- Давайте как-то заставим сеть делать непрерывное латентное пространство






Standard Autoencoder
(direct encoding coordinates)




Variational Autoencoder
(μ and σ initialize a probability distribution)


Просто добавить μ и σ is not enough



What we require



What we may inadvertently end up with




Добавим метрику схожести распределений


Kullback-Leibler расходимость

$$\sum_{i=1}^n \sigma_i^2 + \mu_i^2 - \log(\sigma_i) - 1$$

Но При использовании KL потерь области кодирования расположены случайным образом в окрестности выделенной точки в скрытом пространстве со слабым учётом сходства между образцами входных данных. Поэтому декодер не способен извлечь что-либо значащее из этого пространства





Добавим метрику
потерь
восстановления из
пространства как у
АЕ



Как выглядит пр-
во в идеале?

А вот так ->

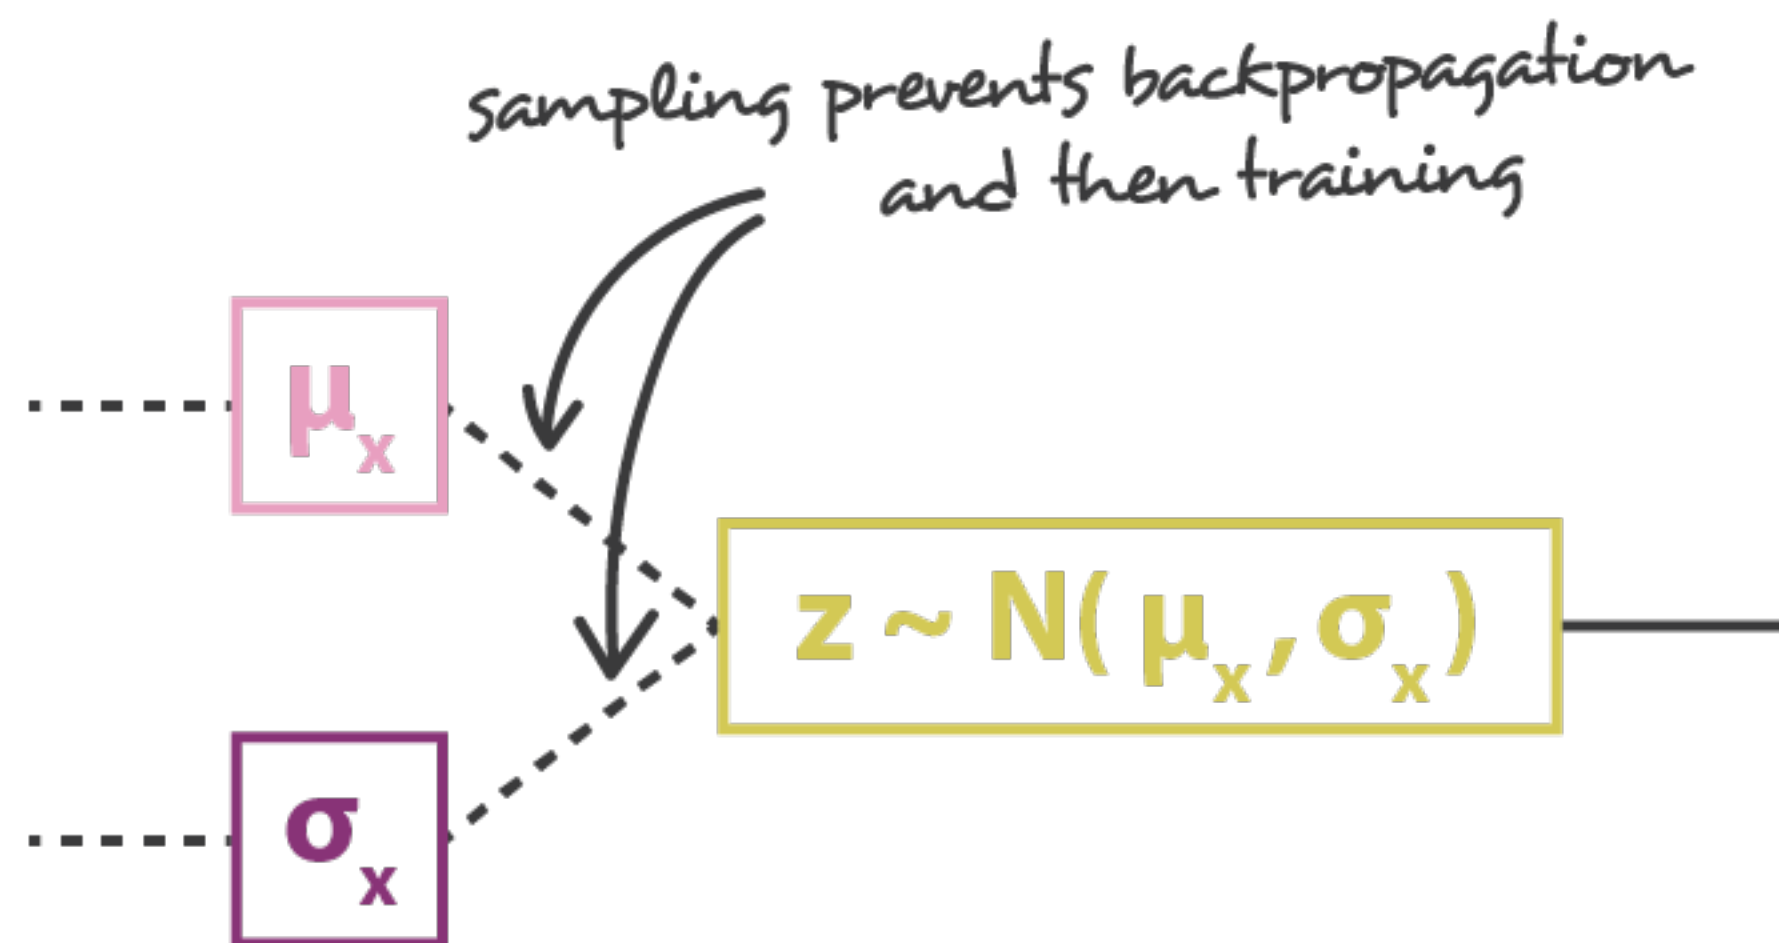




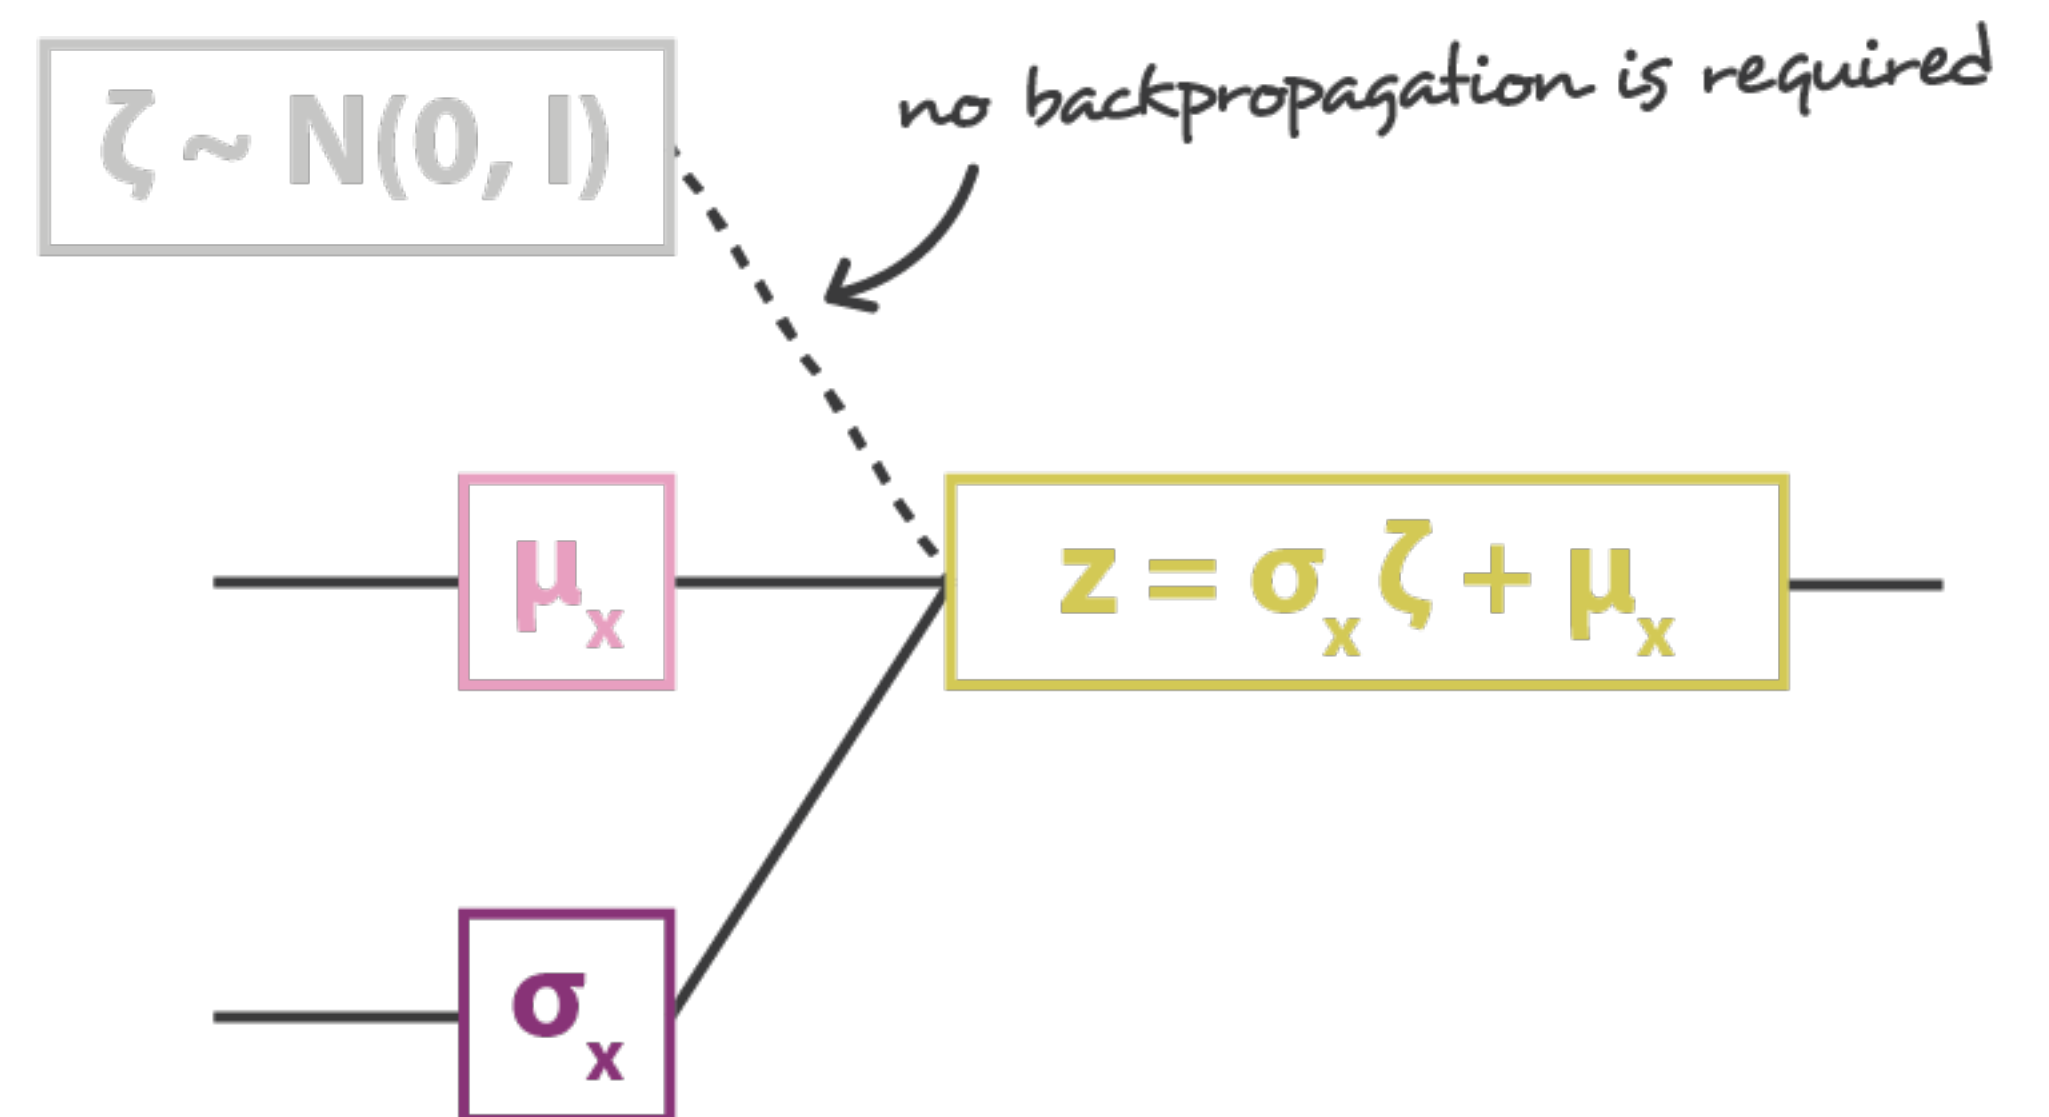
Reparametrization Trick

—— no problem for backpropagation


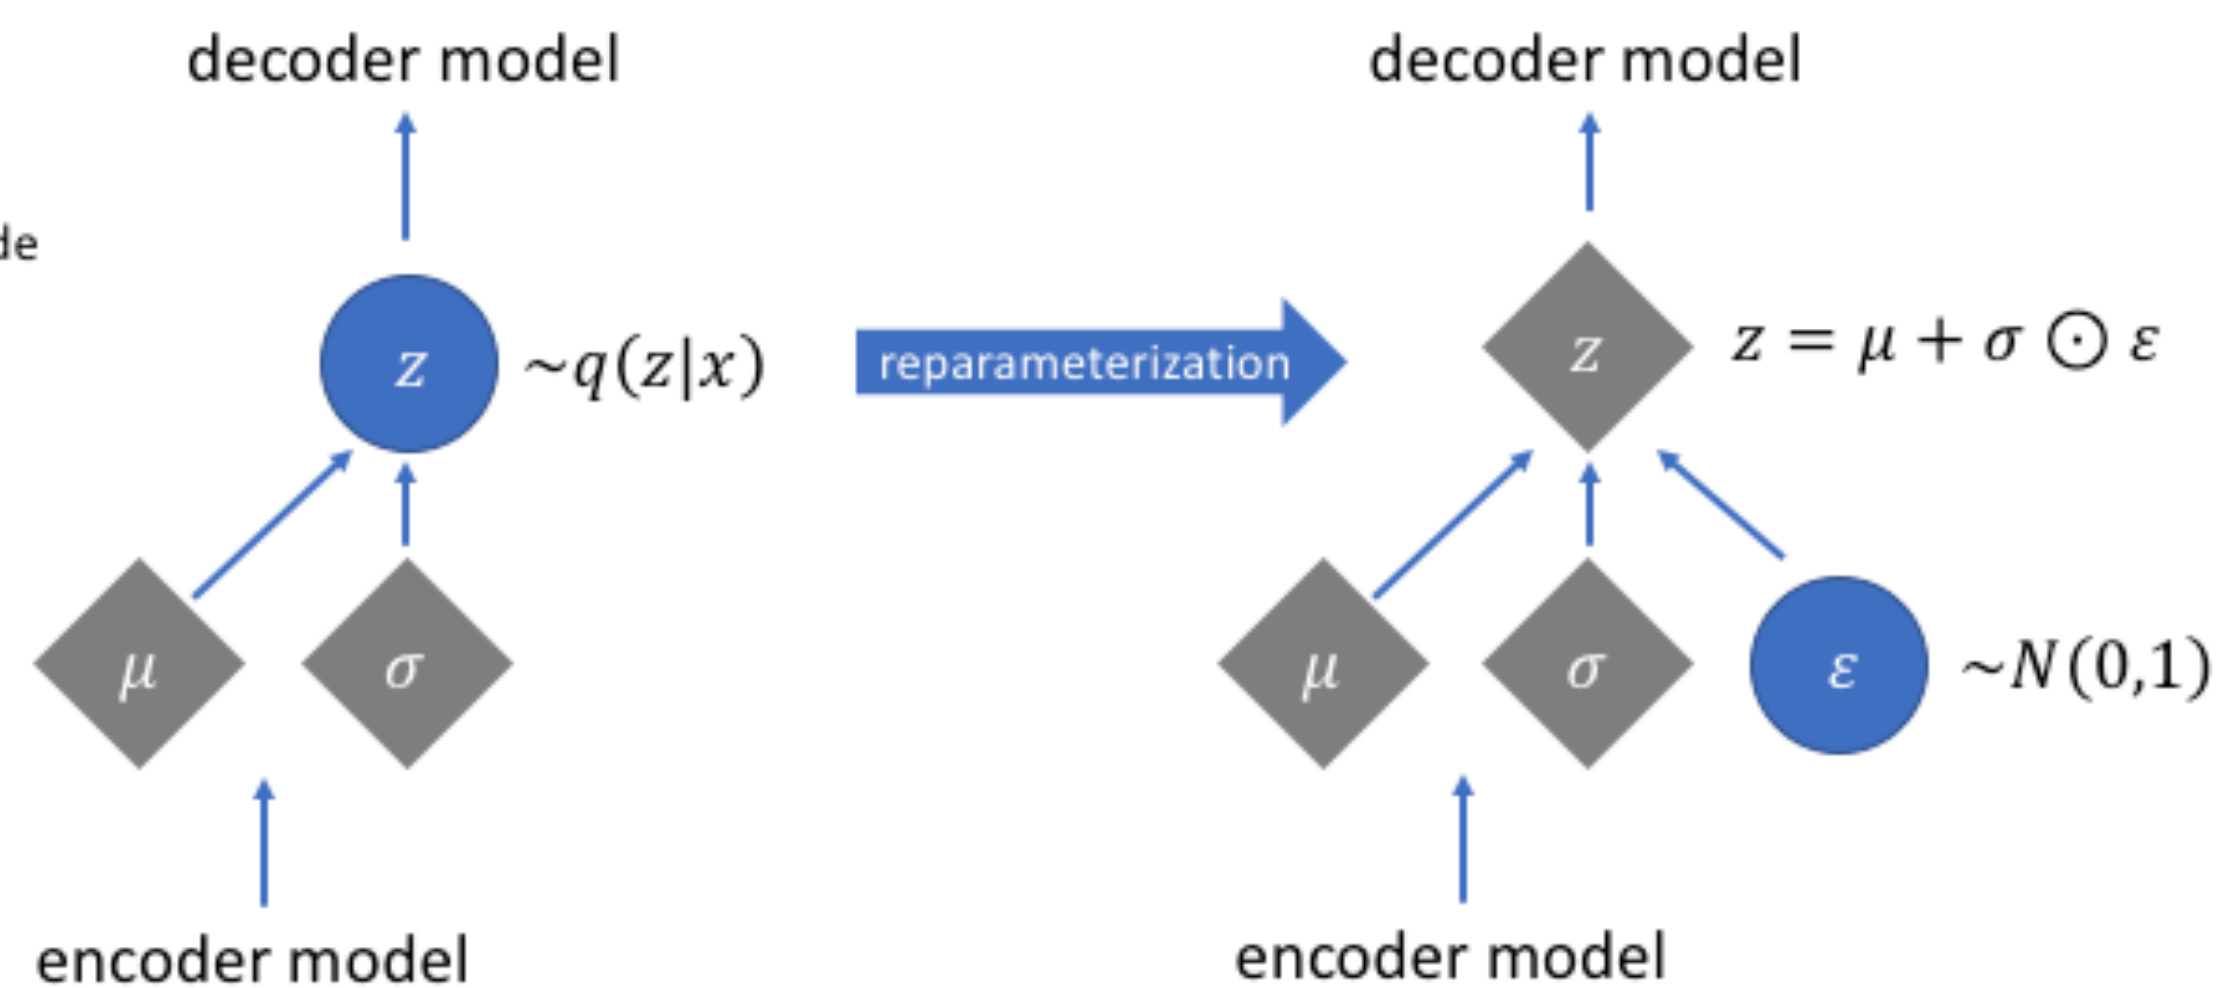
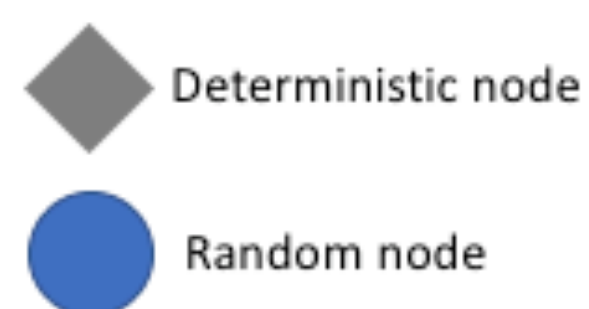
..... backpropagation is not possible due to sampling



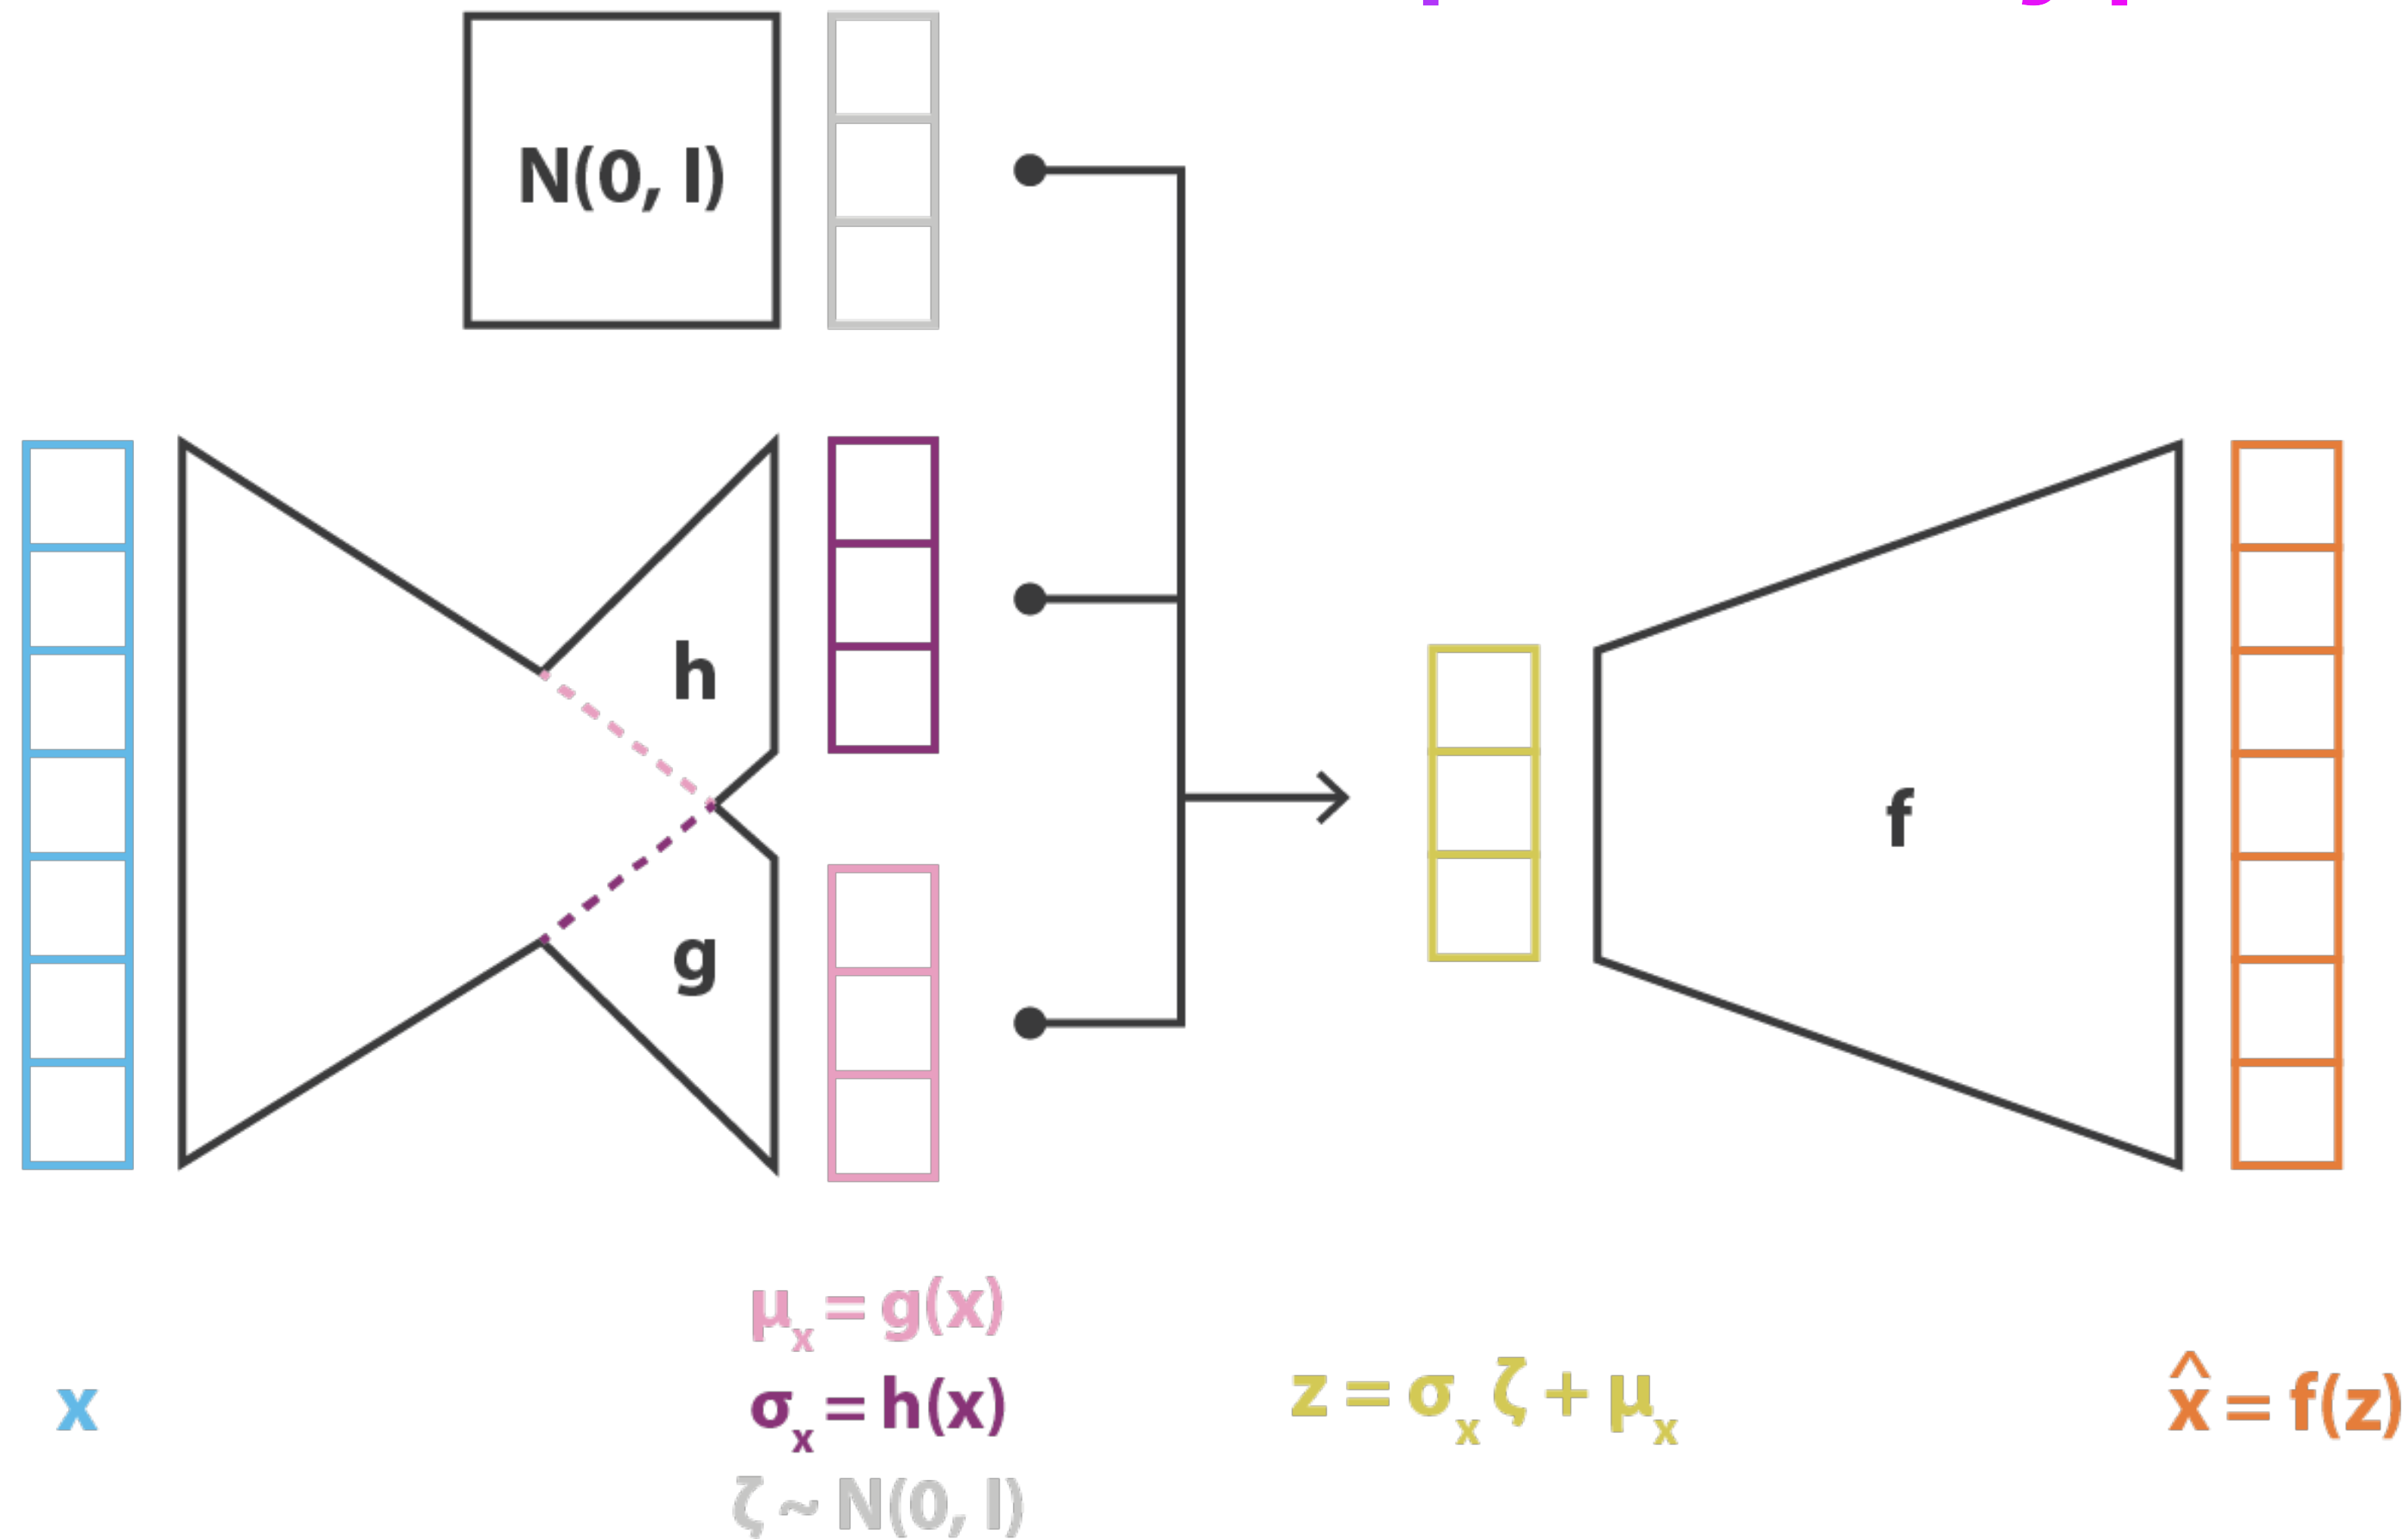
sampling without reparametrisation trick



sampling with reparametrisation trick




Итоговая схема архитектуры



$$\text{loss} = C || x - \hat{x} ||^2 + \text{KL}[N(\mu_x, \sigma_x), N(0, I)] = C || x - f(z) ||^2 + \text{KL}[N(g(x), h(x)), N(0, I)]$$

Cycle GAN TL;DR



- Вводится $G : X \rightarrow Y$ и $F : Y \rightarrow X$ и D_x с D_y
- D_y учит переводить изображения X в Y , D_x обратно
- В итоге получаем обратимые преобразования

$$\bar{x} \rightarrow G(\bar{x}) \rightarrow F(G(\bar{x})) \approx \bar{x}$$

$$\bar{y} \rightarrow F(\bar{y}) \rightarrow G(F(\bar{y})) \approx \bar{y}$$

Функции потерь

Состязательная функция потерь

$$\begin{aligned}\mathcal{L}_{GAN}(G, D_Y, X, Y) &= \mathbb{E}_{\bar{y} \sim p_{data}(\bar{y})} [\log D_Y(\bar{y})] \\ &\quad + \mathbb{E}_{\bar{x} \sim p_{data}(\bar{x})} [\log(1 - D_Y(G(\bar{x})))] \\ \mathcal{L}_{GAN}(F, D_X, Y, X) &= \mathbb{E}_{\bar{x} \sim p_{data}(\bar{x})} [\log D_X(\bar{x})] \\ &\quad + \mathbb{E}_{\bar{y} \sim p_{data}(\bar{y})} [\log(1 - D_X(F(\bar{y})))]\end{aligned}$$

Циклическая

$$\mathcal{L}_{cyc}(G, F) = \mathbb{E}_{\bar{x} \sim p_{data}(\bar{x})} [\|F(G(\bar{x})) - \bar{x}\|_1] + \mathbb{E}_{\bar{y} \sim p_{data}(\bar{y})} [\|G(F(\bar{y})) - \bar{y}\|_1]$$

$$\begin{aligned}\mathcal{L}(G, F, D_X, D_Y) &= \mathcal{L}_{GAN}(G, D_Y, X, Y) + \mathcal{L}_{GAN}(F, D_X, Y, X) \\ &\quad + \lambda \mathcal{L}_{cyc}(G, F)\end{aligned}$$

Monet ↔ Photos



Monet → photo




photo → Monet

Zebras ↔ Horses



zebra → horse



horse → zebra

Summer ↔ Winter



summer → winter



winter → summer



Photograph



Monet



Van Gogh



Cezanne



Ukiyo-e

Спасаем цветовую палитру

$$L_{identity}(G, F) = \mathbb{E}_{y \sim p_{data}(y)} [\|G(y) - y\|_1] + \mathbb{E}_{x \sim p_{data}(x)} [\|F(x) - x\|_1]$$

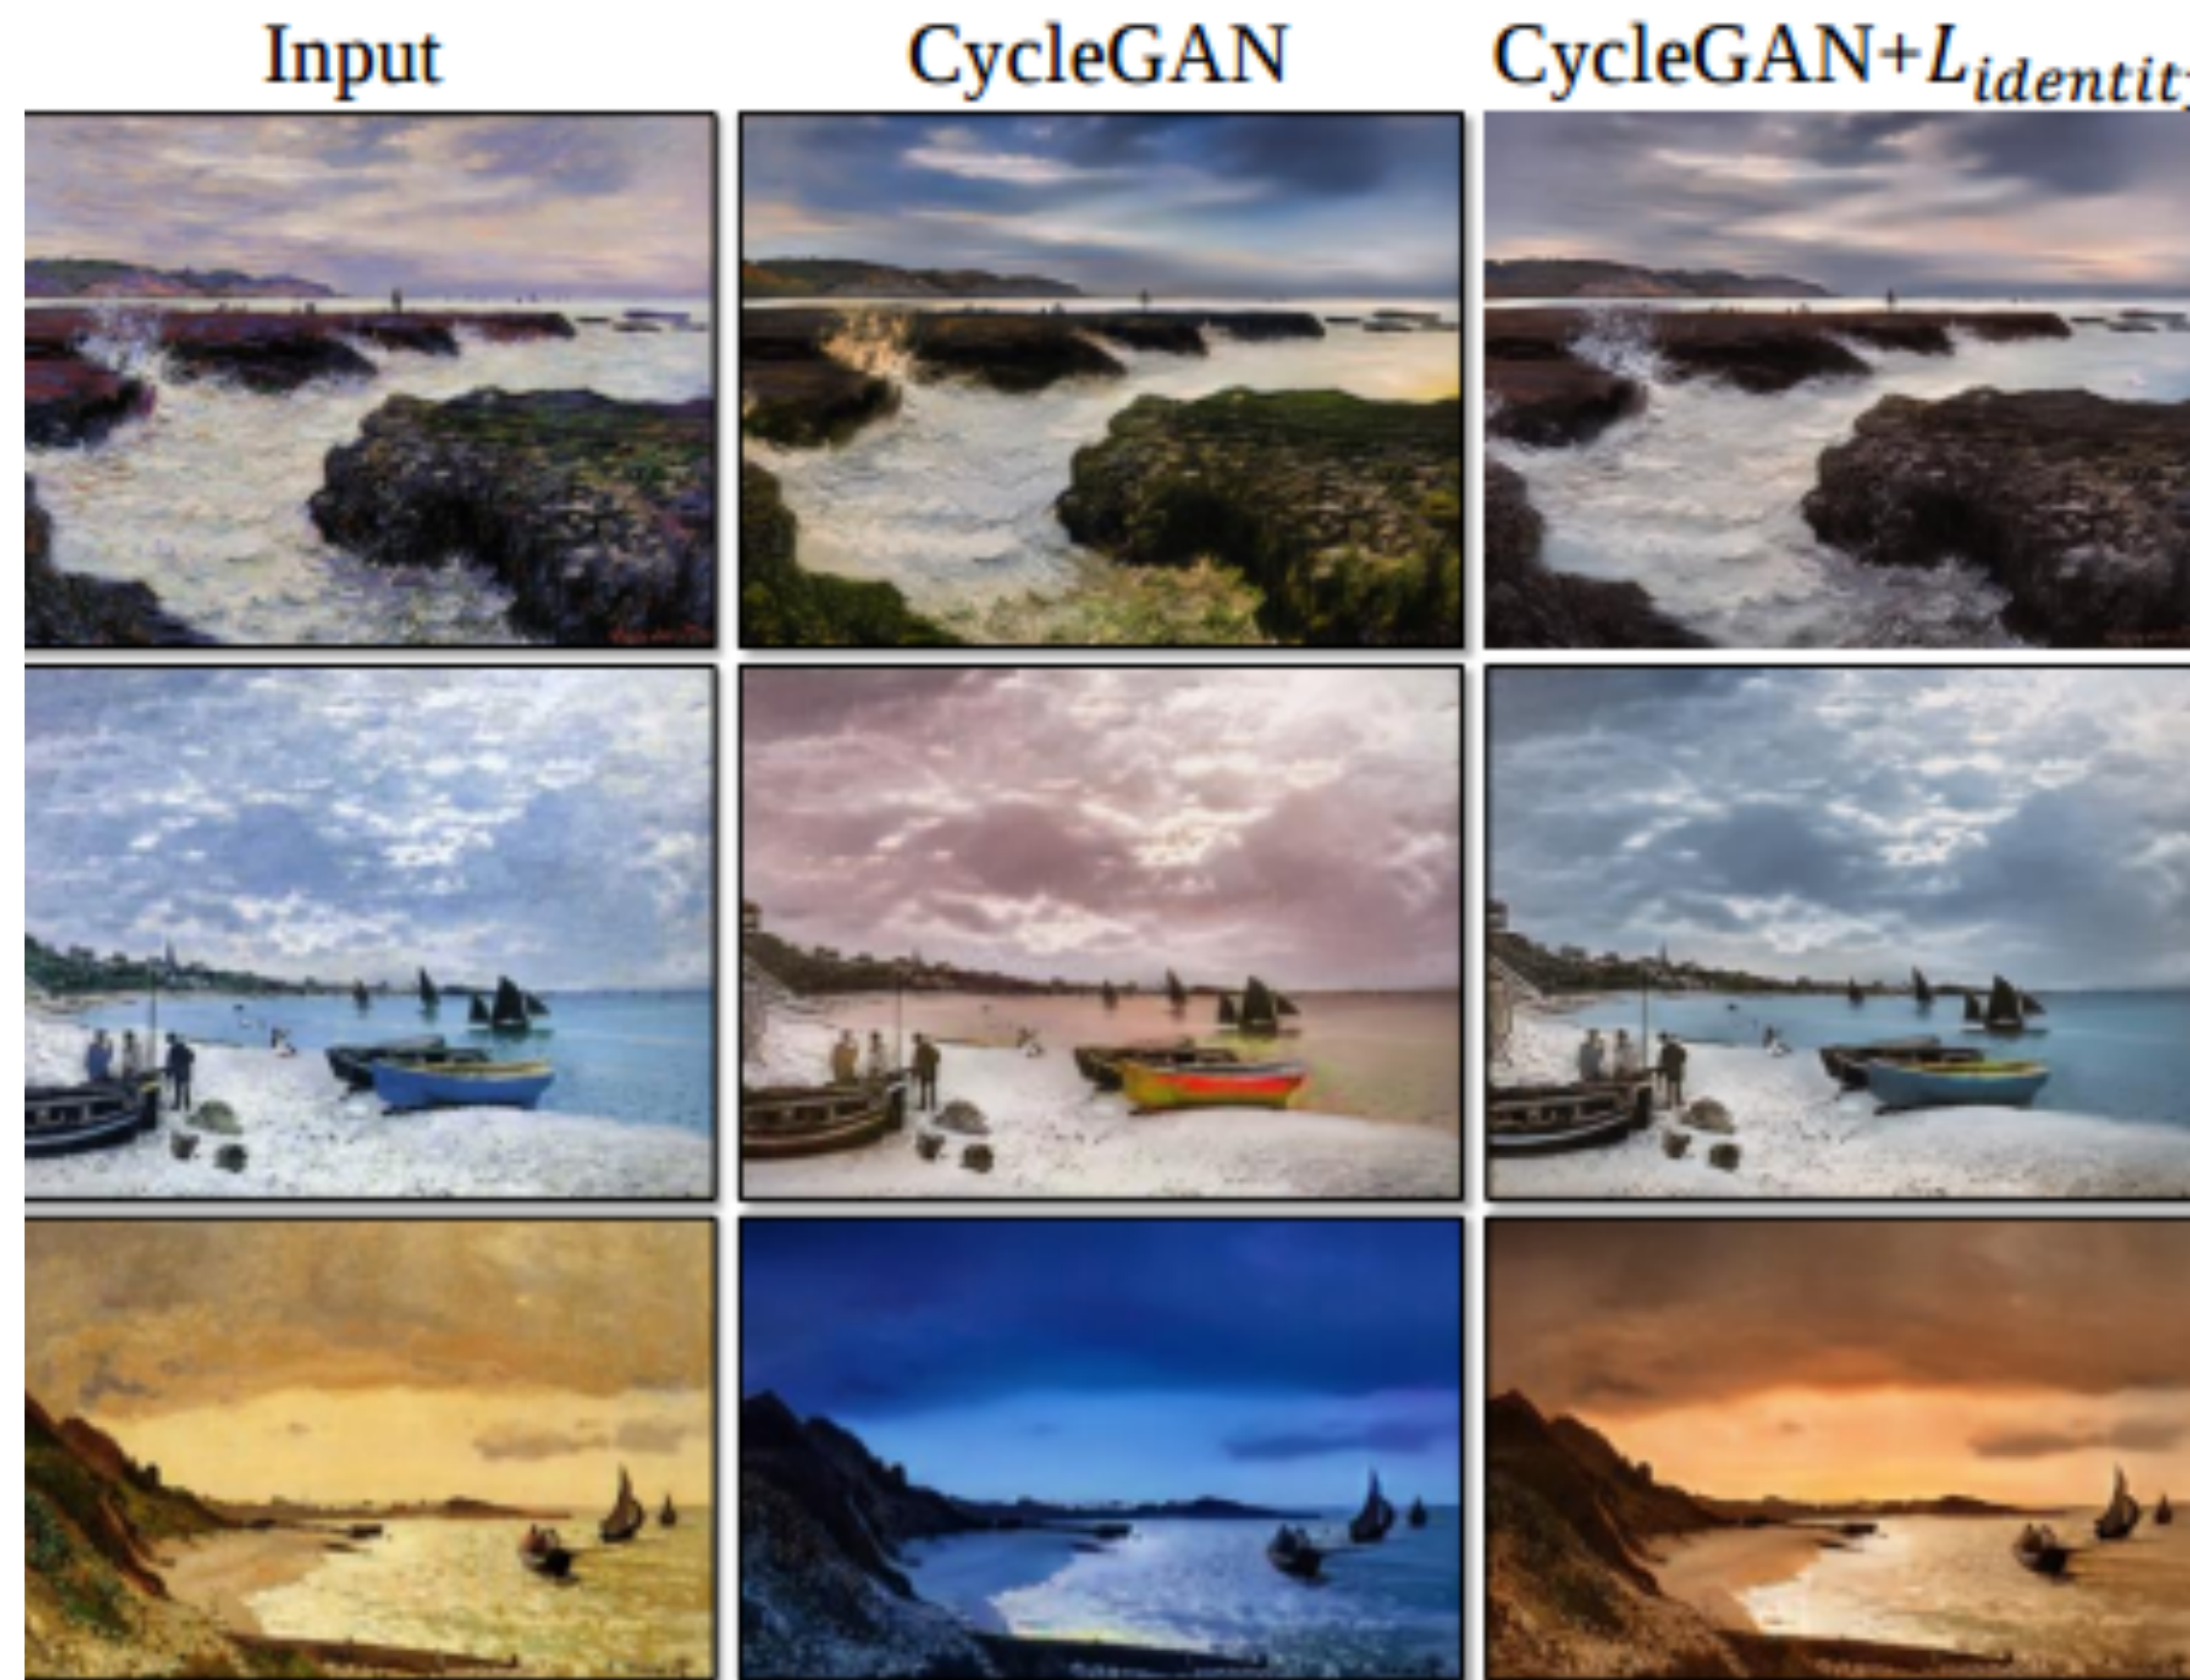


Figure 9: The effect of the *identity mapping loss* on Monet \rightarrow Photo. From left to right: input paintings, CycleGAN without identity mapping loss, CycleGAN with identity mapping loss. The identity mapping loss helps preserve the color of the input paintings.